

Challenge AWS AI Practitioner Certified



AWS COMMUNITY
CARTAGENA

BIENVENIDOS



Semana 2: Fundamentos de machine learning e inteligencia artificial



AWS COMMUNITY
CARTAGENA

Acerca de mí




CloudOps Guild
Together, towards mastery in Cloud and DevOps



Esposo y padre de 2 hijos, Ángel y Sara
Ingeniero de sistemas, especialista en telecomunicaciones, MBA
Trabajo en el campo de la tecnología hace más de 20 años.

Áreas de especialización

- Arquitectura TI
- DevOps
- Site Reliability Engineering
- Arquitectura multi cloud (AWS, Azure, OCI)
- <https://www.linkedin.com/in/mario-rodrigo-serrano-pineda/>
- E-mail: marosepi2020@gmail.com
- <https://medium.com/@marioserranopineda>



AGENDA




CloudOps Guild
Together, towards mastery in Cloud and DevOps

1. Fundamentos de machine learning e inteligencia artificial
2. Casos de uso y aplicaciones
3. Prácticas de IA responsable



AWS COMMUNITY
CARTAGENA





AWS COMMUNITY
CARTAGENA

1. Fundamentos de machine learning e inteligencia artificial

Inteligencia Artificial y Machine Learning



CloudOps Guild
Together, towards mastery in Cloud and DevOps



Artificial intelligence

Inteligencia artificial (IA)

La IA es un campo amplio que abarca el desarrollo de sistemas inteligentes capaces de realizar tareas que normalmente requieren inteligencia humana, como la percepción, el razonamiento, el aprendizaje, la resolución de problemas y la toma de decisiones. La IA sirve como un término que abarca varias técnicas y abordajes, incluidos el machine learning, el aprendizaje profundo y la IA generativa, entre otros.




AWS COMMUNITY
CARTAGENA

Inteligencia Artificial y Machine Learning



CloudOps Guild
Together, towards mastery in Cloud and DevOps




Machine Learning (ML)

El ML es un tipo de IA que permite comprender y crear métodos que hacen posible que las máquinas aprendan. Estos métodos utilizan datos para mejorar el rendimiento de las computadoras en un conjunto de tareas.



AWS COMMUNITY
CARTAGENA



Machine Learning




CloudOps Guild
Together, towards mastery in Cloud and DevOps



La creación de un modelo de machine learning implica la recopilación y preparación de datos, la selección de un algoritmo adecuado, el entrenamiento del modelo con los datos preparados y la evaluación de su rendimiento mediante pruebas e iteraciones.



AWS COMMUNITY
CARTAGENA



Machine Learning



CloudOps Guild
Together, towards mastery in Cloud and DevOps

Hay varios tipos diferentes de datos que se utilizan para entrenar un modelo de ML.

Datos etiquetados

Los datos etiquetados son un conjunto de datos en el que cada instancia o ejemplo va acompañado de una etiqueta o variable de destino que representa el resultado o la clasificación que se espera. Por lo general, estas etiquetas las proporcionan expertos humanos o se obtienen mediante un proceso confiable.

Ejemplo: En una tarea de clasificación de imágenes, los datos etiquetados consistirían en imágenes junto con sus etiquetas de las clases correspondientes (por ejemplo, *gato*, *perro*, *automóvil*).


Datos sin etiquetar

Los datos sin etiquetar son un conjunto de datos en el que las instancias o los ejemplos no tienen etiquetas ni variables de destino asociadas. Los datos se componen únicamente de características de entrada, sin ningún resultado ni una clasificación correspondiente.

Ejemplo: Una recopilación de imágenes sin etiquetas ni anotaciones.



AWS COMMUNITY
CARTAGENA



Proceso de machine learning




CloudOps Guild
Together, towards mastery in Cloud and DevOps

El proceso de ML se divide tradicionalmente en tres categorías amplias: *aprendizaje supervisado*, *aprendizaje no supervisado* y *aprendizaje por refuerzo*.



En el *aprendizaje supervisado*, los algoritmos se entrenan con datos etiquetados. El objetivo es aprender una función de mapeo que pueda predecir el resultado de nuevos datos de entrada no vistos.



El *aprendizaje no supervisado* se refiere a los algoritmos que aprenden de datos no etiquetados. El objetivo es descubrir patrones, estructuras o relaciones inherentes dentro de los datos de entrada.



En el *aprendizaje por refuerzo*, la máquina solo recibe una puntuación de rendimiento como aprendizaje orientativo y semisupervisado, donde solo se etiqueta una parte de los datos de entrenamiento. La retroalimentación se hace en forma de recompensas o penalizaciones por las acciones de la máquina y esta aprende de estos comentarios para mejorar las decisiones que toma con el paso del tiempo.

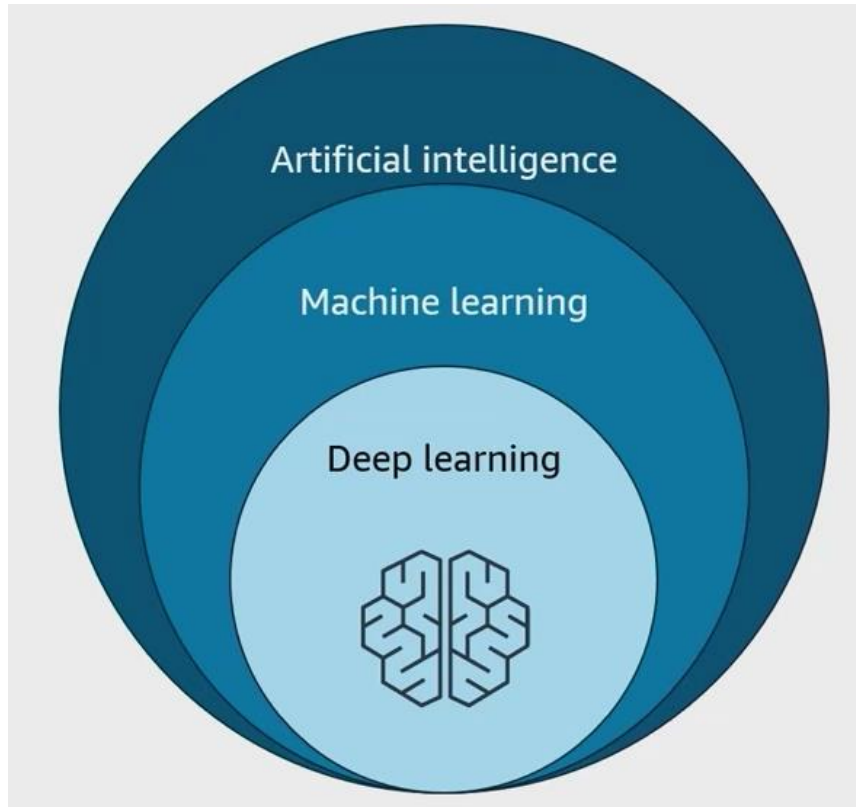


AWS COMMUNITY
CARTAGENA

Inteligencia Artificial y Machine Learning



CloudOps Guild
Together, towards mastery in Cloud and DevOps



Aprendizaje profundo (DL)

El aprendizaje profundo (o deep learning) usa el concepto de neuronas y sinapsis de forma similar a cómo está conectado nuestro cerebro. Un ejemplo de aplicación de aprendizaje profundo es Amazon Rekognition, que puede analizar en cuestión de segundos millones de imágenes y videos en streaming y almacenados.




AWS COMMUNITY
CARTAGENA

Redes neuronales



CloudOps Guild
Together, towards mastery in Cloud and DevOps



En el centro del aprendizaje profundo se encuentran las redes neuronales. Al igual que nuestros cerebros tienen neuronas que están conectadas entre sí, las redes neuronales tienen muchas unidades diminutas llamadas nodos que están interconectados. Estos nodos se organizan en capas. Las capas incluyen una capa de entrada, una o más capas ocultas y una capa de resultados.




AWS COMMUNITY
CARTAGENA

Inteligencia Artificial y Machine Learning



CloudOps Guild
Together, towards mastery in Cloud and DevOps



IA generativa

La IA generativa es un subconjunto del aprendizaje profundo porque puede adaptar modelos creados mediante el aprendizaje profundo, pero sin la necesidad de reentrenamiento ni ajustes.

Los sistemas de IA generativa son capaces de generar nuevos datos en función de los patrones y estructuras aprendidos de los datos de entrenamiento.




AWS COMMUNITY
CARTAGENA

Aspectos básicos de la IA generativa



CloudOps Guild
Together, towards mastery in Cloud and DevOps



La IA generativa se basa en modelos que están entrenados previamente con datos a escala de Internet. Estos modelos se denominan modelos fundacionales (FM).



AWS COMMUNITY
CARTAGENA



AWS COMMUNITY
CARTAGENA

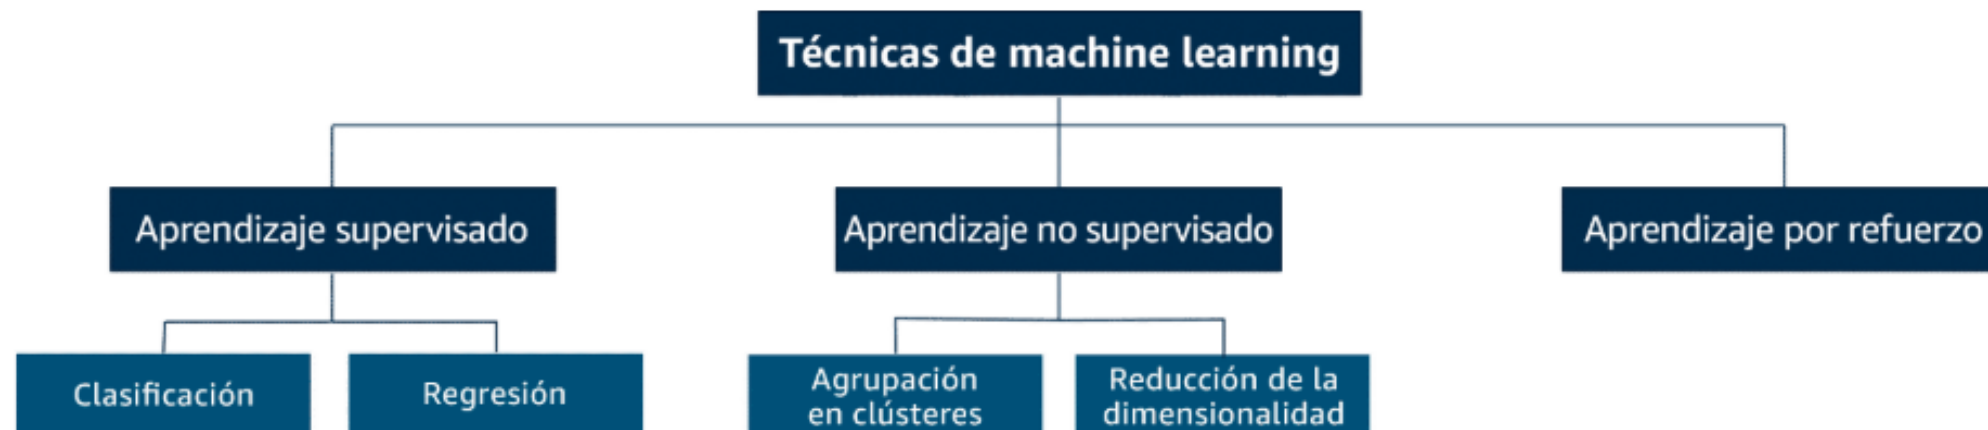
2. Casos de uso y aplicaciones



Técnicas de machine learning y casos de uso

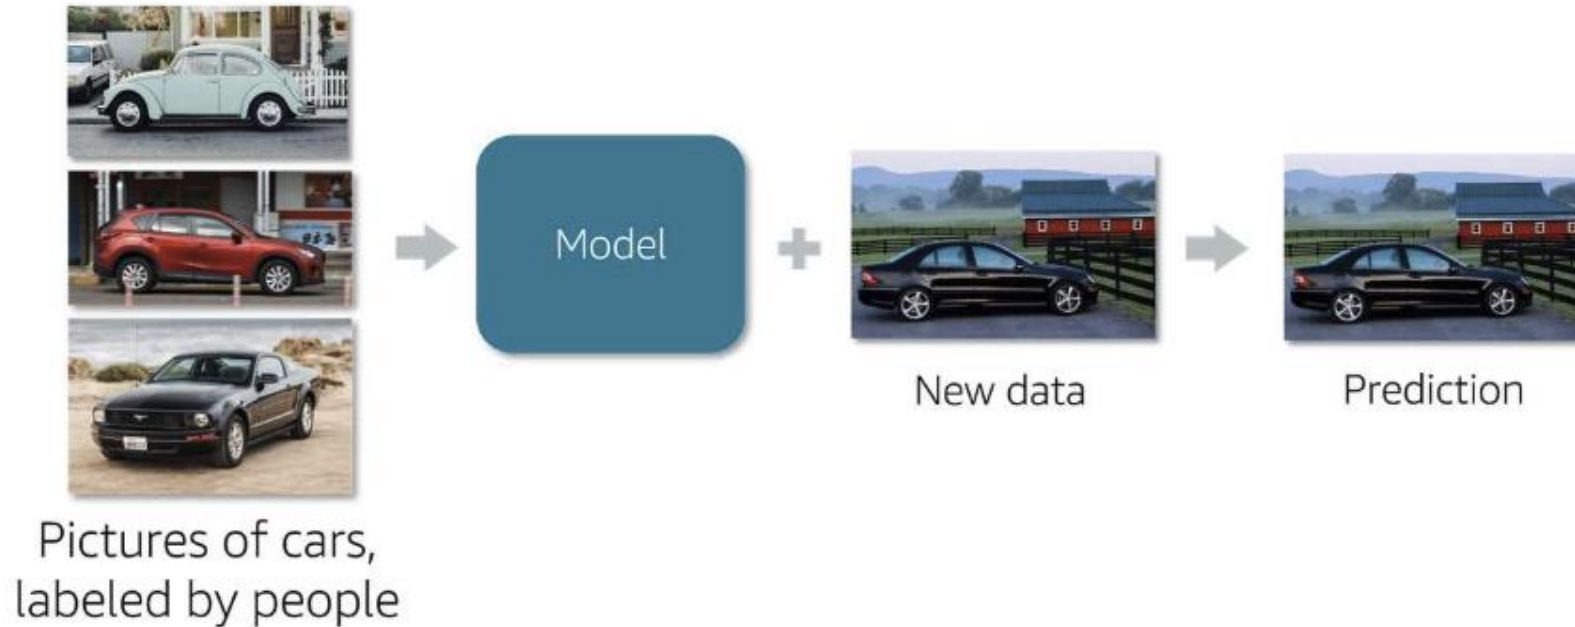
Las técnicas de aprendizaje de ML representan la columna vertebral de la IA moderna y permiten a los sistemas aprender de los datos y tomar decisiones inteligentes sin programación explícita.

Estas técnicas incluyen el aprendizaje supervisado, el aprendizaje no supervisado y el aprendizaje por refuerzo, cada uno de los cuales tiene un propósito distinto.





Tipos de aprendizaje



Aprendizaje supervisado

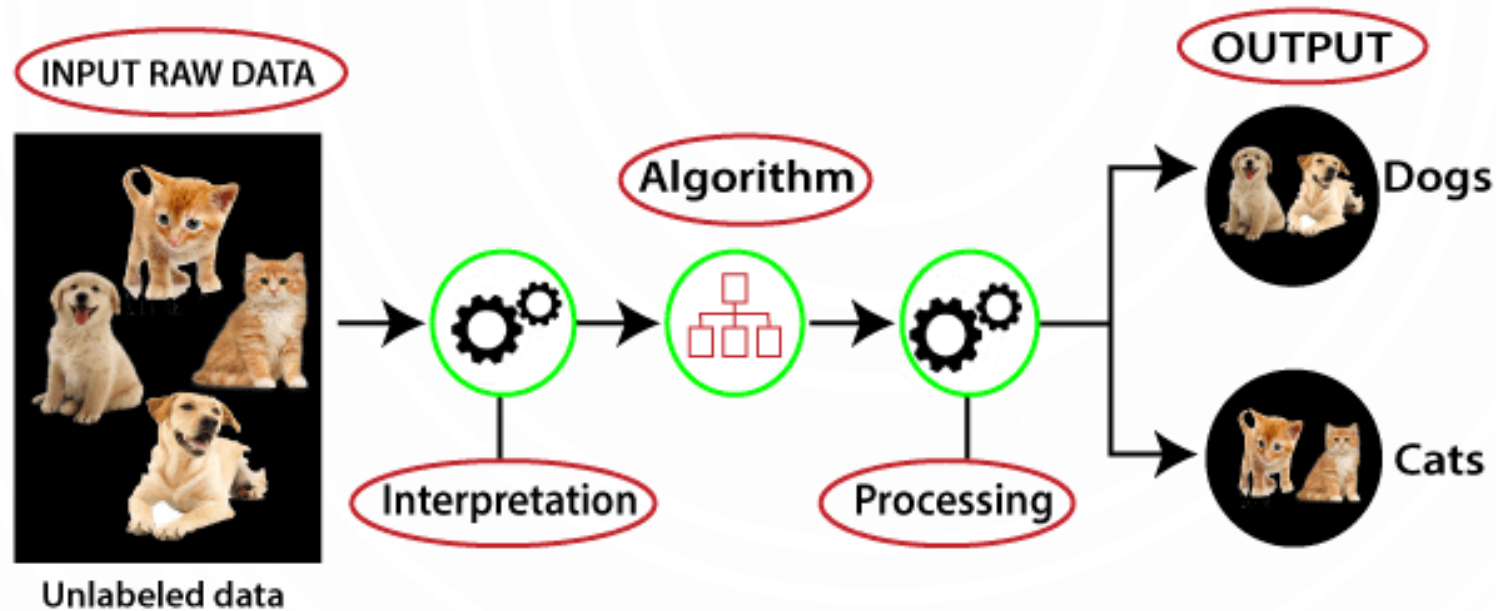
En el aprendizaje supervisado, los algoritmos se entrenan con datos etiquetados.

El objetivo es aprender una función de mapeo que pueda predecir la salida de datos de entrada nuevos e invisibles.





Tipos de aprendizaje



Aprendizaje no supervisado


El aprendizaje no supervisado se refiere a algoritmos que aprenden a partir de datos sin etiquetar.

El objetivo es descubrir patrones, estructuras o relaciones inherentes dentro de los datos de entrada.





Tipos de aprendizaje



El agente es el automóvil virtual y el entorno es una pista de carreras virtual.

Aprendizaje por refuerzo

En el aprendizaje por refuerzo, la máquina recibe solo una puntuación de rendimiento como guía y el aprendizaje semisupervisado, donde solo se etiqueta una parte de los datos de entrenamiento.

La retroalimentación se proporciona en forma de recompensas o sanciones por sus acciones y la máquina aprende de esta retroalimentación para mejorar su toma de decisiones con el tiempo.





AWS COMMUNITY
CARTAGENA

3. Prácticas de IA responsable



Prácticas de la IA responsable

¿Qué es la IA responsable?

La IA responsable se refiere a las prácticas y los principios que garantizan que los sistemas de IA sean transparentes y confiables, al tiempo que mitigan los posibles riesgos y resultados negativos. Estos estándares de responsabilidad deben tenerse en cuenta durante todo el ciclo de vida de una aplicación de IA. Se incluyen las fases iniciales de diseño, desarrollo, implementación, supervisión y evaluación.

Para operar la IA de manera responsable, las empresas deben garantizar de manera proactiva que su sistema cuenta con las siguientes características:

- Es totalmente transparente y responsable, y cuenta con mecanismos de supervisión y vigilancia.
- Su gestión está a cargo de un equipo de liderazgo que responde a las estrategias de IA responsable.
- Su desarrollo está a cargo de equipos con experiencia en principios y prácticas de IA responsable.
- Se creó siguiendo las pautas de IA responsable.





Desafíos de la IA responsable

Exactitud de los modelos

El principal problema al que se enfrentan los desarrolladores en las aplicaciones de IA es la exactitud.

El sesgo es uno de los mayores desafíos a los que se enfrenta un desarrollador en los sistemas de IA. El sesgo en un modelo significa que al modelo le faltan características importantes de los conjuntos de datos. Esto quiere decir que los datos son demasiado básicos. El sesgo se mide por la diferencia entre las predicciones que se esperan del modelo y los valores reales que intentamos predecir.

La varianza presenta un desafío diferente para los desarrolladores. La varianza se refiere a la sensibilidad del modelo a las fluctuaciones o al ruido en los datos de entrenamiento. El problema es que el modelo podría considerar que el ruido en los datos es importante en los resultados.





CloudOps Guild
Together, towards mastery in Cloud and DevOps

Desafíos de la IA responsable

Exactitud de los modelos

El principal problema al que se enfrentan los desarrolladores en las aplicaciones de IA es la exactitud.

La compensación entre sesgo y varianza se produce cuando se optimiza el modelo con el equilibrio adecuado entre sesgo y varianza. Esto significa que se debe optimizar el modelo para que no quede subajustado o sobreajustado. El objetivo es lograr un modelo entrenado con el sesgo más bajo y la menor varianza para un conjunto de datos determinado.

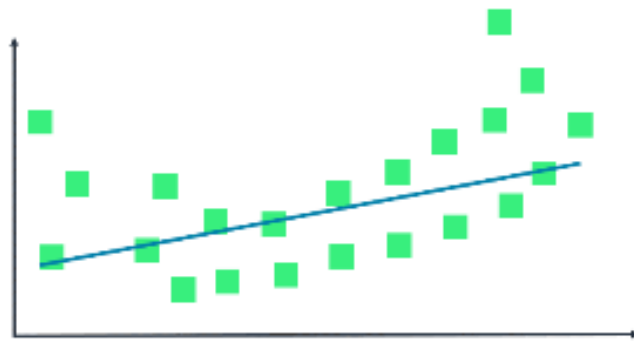


AWS COMMUNITY
CARTAGENA




Desafíos de la IA responsable

La compensación entre sesgo y varianza se produce cuando se optimiza el modelo con el equilibrio adecuado entre sesgo y varianza. Esto significa que se debe optimizar el modelo para que no quede subajustado o sobreajustado. El objetivo es lograr un modelo entrenado con el sesgo más bajo y la menor varianza para un conjunto de datos determinado.




Underfitted

En el ejemplo subajustado, el sesgo es alto y la varianza es baja. En este caso, la regresión es una línea recta. De este modo, vemos que el modelo está subajustando los datos porque no captura todas sus características.



Overfitted

En el ejemplo sobreajustado, el sesgo es bajo y la varianza es alta. En este caso, la curva de regresión se ajusta perfectamente a los datos. Esto significa que captura el ruido y, básicamente, memoriza los datos. No funcionará bien con datos nuevos.



Balanced

En el ejemplo equilibrado, el sesgo y la regresión son bajos. En este caso, la regresión es una curva. Esto es lo que usted necesita. Que el modelo capture suficientes características de los datos, sin capturar el ruido.





Dimensiones fundamentales de la IA responsable



Agradecimientos



CloudOps Guild
Together, towards mastery in Cloud and DevOps



Próxima sesión:

Desarrollo de soluciones de ML e IA,.



**AWS COMMUNITY
CARTAGENA**